


Estrutura Geral do Projeto



data

Pasta com os arquivos PDF originais utilizados como entrada no pipeline de extração. Cada arquivo é processado individualmente para geração de markdown e posterior indexação vetorial.

data_md

Pasta que armazena os arquivos markdown finais gerados a partir dos PDFs. Esses arquivos já passaram por OCR, estruturação e limpeza de tabelas, sendo a base para o processo de chunking e vetorização.

md_images

Pasta destinada ao armazenamento das imagens extraídas dos PDFs durante a conversão com Docling. As imagens são salvas separadamente e referenciadas no markdown.

venv

Ambiente virtual do projeto contendo as dependências instaladas via requirements.txt. Garante isolamento e reprodutibilidade do ambiente de execução.

pipelineExtractorPdf.py

Script principal do pipeline de processamento. Responsável por:

Importação de bibliotecas para OCR, processamento de PDF, chunking e vetorização

Configuração do ambiente Tesseract para OCR em português

Conversão de PDF para markdown utilizando Docling com suporte a OCR e extração de tabelas

Limpeza de textos e correção de artefatos de encoding

Extração e tratamento de tabelas em markdown

Geração de chunks de texto respeitando tamanho máximo e preservando estrutura de tabelas

Criação e gerenciamento de coleção no Qdrant

Geração de vetores densos com SentenceTransformer

Geração de vetores esparsos com modelo SPLADE

Inserção dos chunks no banco vetorial com metadados estruturados

Funções principais do script

clean_text

Remove artefatos de glyph e problemas de codificação gerados na conversão do PDF.

pass_to_markdown_docling

Executa a conversão do PDF para markdown utilizando Docling.

Ativa OCR em português

Detecta estrutura de tabelas

Extraí imagens

Exporta markdown e estrutura interna do documento

docling_chunking

Realiza chunking estruturado utilizando HybridChunker do Docling, enriquecendo o contexto dos blocos textuais.

extract_markdown_tables

Identifica tabelas no markdown e aplica limpeza avançada nas células, removendo resíduos de OCR e normalizando notações técnicas.

extract_full_markdown_with_clean_tables

Reconstrói o markdown final substituindo tabelas por versões limpas e removendo arquivos intermediários.

Processo de Chunking Manual

Leitura linha a linha do markdown

Remoção de linhas vazias ou compostas apenas por separadores

Agrupamento de parágrafos até o limite de 1024 caracteres

Preservação de blocos de tabela como unidade única

Geração de lista final de chunks prontos para vetorização

Integração com Qdrant

Criação da coleção sb100

Configuração de vetores densos com similaridade cosseno

Configuração de vetores esparsos com índice interno

Geração de embeddings densos com modelo Qwen
Geração de embeddings esparsos com modelo OpenSearch Neural Sparse Encoding
Inserção de cada chunk como ponto no banco vetorial
Armazenamento de metadados contendo conteúdo, nome do arquivo, índice do chunk, tamanho, tipo e data de ingestão

requirements.txt

Arquivo contendo as dependências do projeto como Docling, SentenceTransformers, Transformers, Qdrant Client, Torch e demais bibliotecas necessárias para execução do pipeline.

sq2.log

Arquivo de log do sistema contendo registros de execução, mensagens de erro ou informações de debug.

Objetivo do Pipeline

Automatizar a conversão de documentos PDF científicos em representações estruturadas e vetorizadas, permitindo indexação híbrida densa e esparsa em banco vetorial para aplicações de busca semântica e recuperação de informação.