

E04.010 - Migração do extrator: Docling x Chandra OCR 2

Relatório de avaliação comparativa | 10 PDFs (75 páginas) | Squad 02 - Ingestão e Vetorização

1. Objetivo e criterio de aceite

Migrar a configuração do extrator para a de melhor desempenho com os recursos gratuitos disponíveis. Critério: realizar 10 testes de extração com a configuração atual (Docling + Tesseract) e a nova (Chandra OCR 2), e a diferença de desempenho deve ser de pelo menos 30% a favor da melhor configuração.

2. Metodo

Os 10 PDFs foram processados pelos dois extratores. Cada pagina foi avaliada comparando a extração de cada ferramenta com a IMAGEM REAL da pagina (referencia), em quatro critérios pontuados de 0 a 10: fidelidade do Texto, Tabelas (detecção e conteúdo), Figuras (detecção e descrição) e Layout (preservação da estrutura). O ganho relativo é reportado com e sem a modalidade Figuras, já que o Docking nao descreve imagens nativamente (no pipeline atual isso é feito pelo Gemini, em etapa separada) - assim o resultado não depende dessa assimetria estrutural.

3. Resultado

Veredito: o Chandra OCR 2 superou o Docling em todos os 10 testes. Nota geral: Docling 4.78 -> Chandra 8.47, ganho de +77.5%. Sem a modalidade Figuras, o ganho é de +75.8%. Em ambas as formas de contar, o critério de 30% é atingido com folga.

3.1 Medias por criterio

Criterio	Docling	Chandra	Ganho %
Texto	6.30	9.00	+42.9%
Tabelas	4.30	8.20	+90.7%
Figuras	4.20	7.70	+83.3%
Layout	4.30	9.00	+109.3%
GERAL	4.78	8.47	+77.5%

3.2 Notas por PDF (D = Docling, C = Chandra)

PDF	Pgs	Txt D	Txt C	Tab D	Tab C	Fig D	Fig C	Lay D	Lay C
Boaretto (2007) - 15N citrus	6	6	9	4	9	3	8	4	9
Boaretto (2012) - Leaf NH3	10	6	9	5	8	3	8	4	9
Figueiredo (2005) - Limao	4	7	9	5	8	7	7	5	9
Figueiredo (2006) - Murcott	3	7	9	5	8	7	7	5	9
Influence of INM - sugarcane	5	6	9	5	8	3	8	4	9
Mattos (2005) - NK Fruit quality	2	6	9	4	8	3	8	4	9
Mattos (2010) - NCa Tahiti	8	7	9	5	8	7	7	5	9
Quaggio (2003) - BZn Guacho	8	6	9	4	9	3	8	4	9
ROOTING - micrototeles	8	6	9	1	8	3	8	4	9
Rozane (2011) - Codawork	11	6	9	5	8	3	8	4	9

4. Evidências verificadas (contra a imagem real)

Texto / notação científica: O Docling leu o isótopo "15N" como "oN"/"(N)" (erro semântico) e converteu números de nota de rodapé em símbolos (! * '). Esses artefatos ocorrem em todos os 10 PDFs; no Chandra, zero. O Chandra preserva 15N, graus C, aspas e sobrescritos.

Tabelas: Na Tabela 1 da amostra Boaretto(2007) o Docling perdeu vírgulas decimais e dígitos (29,0 virou 290; 225 virou 25), tornando a tabela numericamente incorreta; o Chandra reproduziu os valores exatos e o cabeçalho multinível. Na amostra ROOTING, o Docling não detectou nenhuma das tabelas (0); o Chandra detectou 3.

Figuras: O Chandra detecta e descreve gráficos e logos, e chegou a ler valores aproximados de um gráfico de barras para uma tabela. O Docling apenas preserva a legenda como texto, sem interpretar a figura.

Layout: O Chandra entrega títulos, negrito e estrutura (markdown/HTML); o Docling devolve texto plano sem hierarquia.

5. Conclusão e recomendação

Recomenda-se migrar a configuração do extrator para o Chandra OCR 2. O ganho de desempenho (+77.5% geral, +75.8% sem figuras, win-rate de 10/10) supera com folga o critério de 30%.

6. Ressalvas

- A avaliação foi feita por um único juiz (modelo de visão). Para robustez adicional, um segundo juiz independente (ex.: Gemini) pode confirmar o resultado - a infraestrutura já suporta isso.
- O Chandra, ao interpretar gráficos, gera valores aproximados (marcados com ~), o que é útil mas não é leitura exata; vale registrar como observação.
- Custo computacional: o Chandra OCR 2 exige GPU para rodar em tempo viável, enquanto o Docling roda em CPU. A decisão de migração deve considerar a disponibilidade de GPU gratuita (Colab).