

PROJETO SB100
AGRÔNOMO VIRTUAL

Iniciação Científica FAPESP · Squad 02 · Ingestão e Vetorização

Avaliação Técnica do Chandra OCR 2

Viabilidade de Integração ao Pipeline Multimodal RAG do SB100

Nicolas Alves Witzel da Silva · 22 de abril de 2026

1. Visão Geral do Chandra OCR 2

O Chandra OCR 2, desenvolvido pela Data Lab, é um modelo de estado da arte projetado para converter documentos em PDF e imagens em formatos estruturados, convertendo documentos para os formatos Markdown, HTML e JSON com preservação de informações de layout,. O modelo suporta mais de 90 idiomas, com foco especial em desempenho multilíngue, e apresenta capacidades avançadas para tabelas, equações matemáticas, formulários, manuscritos e layouts complexos com múltiplas colunas.

Para o projeto SB100, o modelo destaca-se por superar alternativas amplamente utilizadas como Tesseract, DeepSeek OCR e Gemini Flash na precisão de extração de documentos científicos. O repositório oficial e o playground estão disponíveis nos links:

GitHub: <https://github.com/datalab-to/chandra>

Playground: <https://www.datalab.to/playground>

2. Desempenho em Português e Contexto Científico

O Chandra OCR 2 apresenta desempenho superior em língua portuguesa em relação aos principais modelos avaliados. A tabela a seguir apresenta os dados do benchmark multilíngue oficial da Data Lab para o idioma português (pt), que testa tabelas, matemática, ordenação, layout e precisão textual:

Modelo	Datalab API	Chandra 2	Gemini 2.5 Flash	GPT-5 Mini
Precisão em PT (%)	97,0%	95,2%	89,4%	90,8%

Tabela 1. Benchmark multilíngue, idioma português (pt). Fonte: Data Lab benchmarks.

Em artigos científicos (benchmark olmocr), o Chandra 2 obteve pontuação geral de 85,9, com 90,2 em documentos ArXiv. A tabela abaixo apresenta os principais resultados do benchmark olmocr com os modelos relevantes para o projeto:

Modelo	ArXiv	Tabelas	Multi coluna	Texto pequeno	Base	Over all
Datalab API	90,4	90,7	83,7	92,3	99,9	86,7
Chandra 2	90,2	89,9	83,5	92,1	99,6	85,9
olmOCR 2	83,0	84,9	83,7	81,9	99,6	82,4
DeepSeek OCR	75,2	79,7	66,7	80,1	99,7	75,4
Mistral OCR API	77,2	60,6	71,3	77,1	99,4	72,0
GPT-4o	53,5	70,0	69,3	60,6	96,8	69,9
Gemini Flash 2	54,5	72,1	61,5	71,5	95,6	63,8

Tabela 2. Benchmark olmocr, seleção dos modelos mais relevantes para o projeto SB100.

Fonte: Data Lab e olmocr repo.

O Chandra 2 é especialmente robusto no tratamento de múltiplas colunas, textos em corpo reduzido e equações matemáticas, elementos recorrentes nos periódicos acadêmicos de citricultura, cana-de-açúcar e bioinsumos que compõem o corpus do SB100.

3. Funcionalidades Relevantes para o SB100

Com base na documentação oficial do Chandra OCR 2, as seguintes funcionalidades são diretamente relevantes para o pipeline do Squad 02:

- Conversão para Markdown, HTML e JSON com informações detalhadas de layout, sendo compatível com o fluxo de chunking e indexação no Qdrant.
- Suporte a 90+ idiomas, com desempenho verificado em português (95,2%), espanhol (89,3%) e inglês, cobrindo os três idiomas do corpus SB100.
- Extração e salvamento automático de imagens e diagramas separadamente do texto, com geração de legendas e dados estruturados associados, representando potencial substituto ou complemento ao filtro OpenCV atual.
- Forte desempenho em tabelas, equações matemáticas e layouts complexos com múltiplas colunas, melhorando a qualidade dos chunks de artigos científicos.
- Suporte a manuscritos e formulários com alta precisão, sendo relevante para documentos de campo agrícola eventualmente incluídos no corpus.

4. Impacto na Arquitetura do Pipeline Squad 02

4.1 Script 1 Extração e Indexação de Texto

A substituição ou complementação do Tesseract via Docling pelo Chandra OCR 2 no Script 1 traria os seguintes benefícios diretos:

- Saída estruturada nativa em Markdown e JSON com metadados de layout, eliminando etapas de pós-processamento para conversão de tabelas ao Qdrant.
- Precisão superior em equações matemáticas comparado ao Tesseract, vital para artigos técnicos de adubação e fisiologia vegetal.
- Melhor desempenho em layouts de múltiplas colunas, reduzindo artefatos de OCR e melhorando a qualidade dos chunks gerados.
- Integração via CLI direta: `chandra input.pdf ./output` gera automaticamente os arquivos `.md`, `.html` e `_metadata.json` prontos para vetorização.

4.2 Scripts 2 e 3 Processamento de Figuras

A funcionalidade de extração isolada de figuras com legendas e dados estruturados é especialmente relevante para o pipeline multimodal:

- O Chandra extrai imagens e diagramas separadamente, salvando-os no diretório de saída com metadados estruturados e legendas geradas automaticamente.
- Esse pré-processamento pode enriquecer o contexto enviado ao Gemini 3.1 Pro Vision no Script 2, facilitando a extração de séries e valores numéricos de gráficos agrônômicos.
- A combinação Chandra (extração e legendagem estruturada) + Gemini (descrição semântica detalhada) representa uma arquitetura de dois estágios potencialmente superior à abordagem atual de filtro OpenCV + Gemini.

5. Implementação Técnica e Escalabilidade

O Chandra OCR 2 suporta dois modos de inferência relevantes para o contexto do Squad 02:

- Inferência local via HuggingFace (`pip install chandra-ocr[hf]`): carregamento direto do modelo no Google Colab com suporte a torch e transformers. Recomenda-se instalar flash attention para melhor desempenho.
- Servidor vLLM com Docker (`chandra_vllm`): modo otimizado para processamento em lote. Benchmarkado em GPU H100 com throughput de 1,44 páginas/segundo em cenários de alta complexidade e estimativa de 2,0 páginas/segundo em uso real.

A integração no Script 1 consistiria em substituir a chamada ao Docling/Tesseract pelo comando CLI do Chandra:

```
chandra input.pdf ./output --method hf --include-images
```

Cada PDF processado gera automaticamente um subdiretório com: arquivo `.md`, arquivo `.html`, metadados em JSON e imagens extraídas, com estrutura diretamente compatível com o pipeline de ingestão atual.

5.1 Opções CLI Relevantes

- `--method [hf|vllm]`: modo de inferência (padrão: `vllm`)

- --page-range TEXT: intervalo de páginas para PDFs (ex: 1-5,7,9-12)
- --max-workers INTEGER: workers paralelos para vLLM
- --include-images / --no-images: extrair e salvar imagens (padrão: incluir)
- --batch-size INTEGER: páginas por lote (padrão: 28 para vllm, 1 para hf)

5.2 Licenciamento

O código do Chandra OCR 2 é distribuído sob licença Apache 2.0. Os pesos do modelo utilizam a licença OpenRAIL-M, gratuita para pesquisa, uso pessoal e startups com faturamento ou investimento inferior a US\$ 2 milhões, desde que o uso não concorra diretamente com a API comercial da Data Lab. O projeto SB100, como iniciação científica FAPESP de caráter acadêmico, enquadra-se plenamente nos termos de uso gratuito.

6. Análise Comparativa Abordagem Atual vs. Chandra OCR 2

Critério	Docling + Tesseract (atual)	Chandra OCR 2
Precisão em PT	~85–90% (estimativa)	95,2–97,0% (benchmark)
Artigos científicos (ArXiv)	Não benchmarked	90,2 (benchmark olmocr)
Tabelas complexas	Limitado (cabeçalhos multilinha)	89,9 (benchmark olmocr)
Múltiplas colunas	Satisfatório	83,5 (benchmark olmocr)
Equações matemáticas	Limitado	Superior (89,3 old scans math)
Extração de figuras	PyMuPDF + OpenCV (manual)	Nativo com legendas e metadados
Saída para RAG	Requer pós-processamento	Markdown/JSON nativo
Custo	Gratuito (open source)	Gratuito (OpenRAIL-M + Apache 2.0)
Compatibilidade Colab	Confirmada	HuggingFace (pip install, a validar)

Tabela 3. Comparação entre a abordagem atual do pipeline e o Chandra OCR 2.

7. Conclusão e Recomendação

O Chandra OCR 2 representa uma alternativa tecnicamente superior ao Tesseract/Docling para o corpus do SB100 em quase todos os critérios avaliados: precisão em português

(95,2% vs ~85–90% estimado), extração de tabelas complexas, preservação de layout e geração de saída estruturada para RAG. A funcionalidade de extração isolada de figuras com metadados e legendas é especialmente relevante para o pipeline multimodal, podendo simplificar ou substituir o filtro OpenCV e enriquecer o contexto enviado ao Gemini.

Recomenda-se conduzir um experimento comparativo em um subconjunto de 5 a 10 PDFs do corpus, com foco especialmente em artigos com tabelas de dados experimentais e múltiplas figuras, para validar empiricamente o ganho de qualidade e a compatibilidade com o ambiente Google Colab antes de uma adoção plena. Caso os resultados confirmem os benchmarks publicados, a migração justifica-se tanto pelo ganho de precisão quanto pela simplificação arquitetural do Script 1.

Referências

Data Lab. (2026). *Chandra OCR 2 README e Benchmarks*. GitHub: <https://github.com/datalab-to/chandra>

Data Lab. (2026). *Datalab Hosted API and Playground*. Disponível em: <https://www.datalab.to>