

PROJETO SB100: AGRÔNOMO VIRTUAL

Relatório de Experimentos de Vetorização

Testes A-D (Chunking) e Teste de Dimensionalidade (512 vs 1024 dims)

Squad 02: Ingestão e Vetorização
IC FAPESP | Abril de 2026

Técnica de Busca:

Nicolas Alves Witzel da Silva | Pedro Henrique

1. Introdução

O projeto SB100: Agrônomo Virtual tem como objetivo construir uma base de conhecimento científico agrícola pesquisável por linguagem natural. A Squad 02 é responsável pelo pipeline de ingestão e vetorização, que transforma PDFs científicos em vetores semânticos armazenados no banco Qdrant Cloud.

Este relatório documenta dois experimentos independentes realizados ao longo do primeiro semestre de 2026: (1) a série de testes A-D sobre tamanho de chunks de texto, conduzida em fevereiro e março; e (2) o teste de dimensionalidade dos vetores (512 vs. 1024 dimensões), conduzido em abril, em colaboração com a Squad 04.

2. Contexto Técnico

2.1 Stack do Pipeline v2

O pipeline v2 opera em três etapas sequenciais:

- Script 1: Extração: Docling + TesseractCLI (por/eng/spa) para OCR; PyMuPDF para renderização de páginas; filtro OpenCV com 3 camadas (cor HSV, fill density, direção de bordas Sobel) para detectar figuras reais.
- Script 2: Descrição de imagens: Gemini 2.0 Flash Preview processa as páginas filtradas e gera descrições ricas com extração de valores numéricos, tendências e equações de regressão.
- Script 3: Vetorização: Qwen3-Embedding-0.6B (denso, 1024 dims, Cosine) + OpenSearch Neural Sparse v2 Distill (SPLADE esperso); upsert no Qdrant Cloud via REST direto (sa-east-1, AWS São Paulo).

2.2 Distinção entre as Variáveis Testadas

É fundamental distinguir os dois parâmetros testados neste relatório:

Parâmetro	Experimento Fev/Mar	Experimento Abr/2026
O que varia	Tamanho do chunk (chars)	Dimensionalidade do vetor (dims)
O que é fixo	Modelo Qwen3, dims = 1024	Chunk = 1024 chars, mesmo modelo
Pergunta central	Quantos chars por chunk?	Quantas dimensões no vetor?

3. Experimento 1: Tamanho de Chunk (Fevereiro/Março 2026)

3.1 Configurações Testadas

Foram testadas quatro configurações de chunking, mantendo o modelo de embedding fixo (Qwen3-Embedding-0.6B, 1024 dims):

Teste	Chunk Size	Overlap	Tabelas	Observação
A	512 chars	128 chars	Markdown	Chunks muito fragmentados
B	1024 chars	256 chars	Markdown	Configuração base
C	1024 chars	256 chars	Texto natural	Melhor para busca semântica
D	2048 chars	512 chars	Texto natural	Chunks muito longos

3.2 Resultado

O Teste C (1024 chars com 256 de overlap e tabelas convertidas para texto natural) apresentou o melhor desempenho geral. A conversão de tabelas markdown para linguagem natural melhorou significativamente a recuperação semântica de dados tabelados, pois o modelo de embedding captura melhor sentenças em prosa do que estruturas de linhas e colunas em formato markdown.

Conclusão adotada em produção: chunk de 1024 chars + 256 overlap + tabelas em texto natural.

4. Experimento 2: Dimensionalidade do Vetor (Abril 2026)

4.1 Motivação

Com a configuração de chunking definida, o segundo experimento investigou o impacto da dimensionalidade do vetor denso na qualidade do retrieval. A hipótese central era: vetores de 512 dimensões, por ocuparem menos memória e terem menor latência de busca, poderiam ser uma alternativa viável ao vetor completo de 1024 dimensões sem perda significativa de qualidade.

4.2 Metodologia

A coleção sb1024hibrid512 foi criada no Qdrant com o seguinte schema:

- vetor_denso_1024: vetor completo gerado pelo Qwen3-Embedding-0.6B (1024 dimensões, distância Cosine)
- vetor_denso_512: vetor gerado por truncagem das primeiras 512 dimensões do vetor 1024, seguida de re-normalização L2
- vetor_esparso: vetor SPLADE gerado pelo OpenSearch Neural Sparse v2 Distill (compartilhado pelos dois cenários)

4.3 Avaliação

A avaliação foi conduzida pela Squad 04 (Pedro Henrique) com 33 questões elaboradas previamente sobre o corpus do SB100. As respostas foram pontuadas em quatro categorias:

Categoria	Pontos	1024 dims	512 dims
Corretas	10 pts	19 questões	12 questões
Interpretação diferente, correta	7 pts	5 questões	7 questões
Incompletas	5 pts	4 questões	5 questões
Erradas	3 pts	5 questões	9 questões
TOTAL		260 / 330	221 / 330
PERCENTUAL		78,8%	67,0%

4.4 Análise dos Resultados

A diferença de 11,8 pontos percentuais entre 1024 dims (78,8%) e 512 dims (67,0%) é estatisticamente expressiva para um corpus técnico especializado como o do SB100. A degradação foi mais pronunciada em:

- Perguntas que exigem recuperação de valores numéricos precisos (dosagens, percentuais, coeficientes)
- Perguntas indiretas que requerem inferência semântica entre conceitos adjacentes
- Perguntas sobre relações entre variáveis em experimentos agrícolas

Os vetores de 512 dims se saíram relativamente melhor em perguntas diretas com correspondência lexical alta, exatamente onde o vetor esparso (SPLADE) já é competente, sugerindo que nesse subconjunto a dimensionalidade extra não acrescenta tanto.

5. Comparação Geral dos Experimentos

Experimento	Variável	Melhor Config.	Resultado
Testes A-D (Fev/Mar)	Tamanho do chunk	1024 chars + 256 overlap	Adotado em produção
Dims 512 vs 1024 (Abr)	Dims do vetor	1024 dims	78,8% vs 67,0%
Próximo passo (proposto)	Modelo de embedding	Qwen3-4B (a testar)	Hipótese: superior ao 0.6B

6. Conclusões

Os dois experimentos documentados neste relatório estabelecem empiricamente as escolhas de configuração do pipeline SB100:

- Chunking: 1024 chars com 256 de overlap e tabelas convertidas para texto natural é a configuração de produção validada.
- Dimensionalidade: 1024 dimensões é claramente superior a 512 dims, com margem de 11,8 pontos percentuais (78,8% vs 67,0%).
- Próximo passo natural: testar o Qwen3-Embedding-4B, que possui maior capacidade semântica e ocupa o melhor ponto de equilíbrio entre qualidade e custo computacional dentro da família Qwen3.

Esses resultados fornecem base quantitativa para as decisões de engenharia do pipeline e serão incluídos no relatório de progresso FAPESP.

7. Próximos Passos

- Testar o Qwen3-Embedding-4B como modelo de embedding denso. A família Qwen3 reporta ganhos consistentes com o aumento de parâmetros (0.6B, 4B e 8B no MTEB multilingual), e o 4B representa o melhor ponto de equilíbrio entre qualidade.
- Documentar os resultados dos novos experimentos no relatório de progresso FAPESP do segundo semestre de 2026.