

E04.011 - Relatório Final

Estratégia struct_sem_max1024_o256 vs chunking fixo c1024_o256

Avaliação de escalonamento dinâmico, critérios de aceite e limitações metodológicas

Base de análise: Boletim 100 (IAC) | Squad 02 - Ingestão e Vetorização

Veredito executivo

A estratégia struct_sem_max1024_o256 demonstrou funcionamento com escalonamento dinâmico do tamanho dos chunks. Porém, o critério de aceite de 10 testes com ganho igual ou superior a 30% sobre o chunk fixo não foi atingido. A tarefa deve ser registrada como parcialmente concluída: comportamento técnico demonstrado, mas ganho de 30% não comprovado.

1. Objetivo da tarefa

Estória: adotar progressivamente a estratégia struct_sem_max1024_o256 como configuração de chunking de produção, buscando resultados de verificação mais acurados para uso do LLM.

Crítérios de avaliação informados: demonstrar a estratégia struct_sem_max1024_o256 funcionando com escalonamento dinâmico do tamanho do chunk e apresentar 10 testes em que o sistema de escalonamento do chunk apresentou resultado melhor que o método de chunk fixo em 30% ou mais.

Item avaliado	Status	Justificativa
Escalonamento dinâmico funcionando	ATENDIDO	O struct_sem apresenta maior dispersão de tamanho: CV=30,4%, contra CV=7,2% do fixo.
Respeito ao teto configurado	ATENDIDO NO TESTE	Na medição feita, 100% dos chunks ficaram abaixo do teto considerado na análise.
10 testes com ganho >= 30%	NÃO ATENDIDO	As avaliações disponíveis indicam diferenças pequenas, de aproximadamente 1,5% a 3,4%, e não 30%.
Adoção como produção	RECOMENDAÇÃO CONDICIONAL	Pode ser adotado por razões estruturais, mas não pelo critério de ganho de 30%.

2. Dados e saídas do notebook

O notebook corrigido coletou os pontos das duas coleções diretamente no Qdrant por REST, usando o endpoint /points/scroll, sem solicitar input manual durante a execução. As duas coleções analisadas foram:

Coleção	Estratégia	Registros carregados	Observação
struct_sem_max1024_o256	Estrutural/semântica com teto 1024 e overlap 256	1283	Estratégia nova, com tamanho variável guiado pela estrutura.
c1024_o256	Chunking fixo com teto 1024 e overlap 256	991	Baseline fixo usado para comparação.

2.1 Inspeção automática do payload

As duas coleções apresentaram o mesmo conjunto principal de campos no payload:

```
['content', 'chunk_index', 'chunk_size', 'pagina_pdf', 'estrategia', 'tipo', 'titulo', 'ano', 'arquivo']
```

Coleção	Campo de texto detectado	Campo de seção detectado	Campo de tokens detectado	Unidade usada no gráfico
struct_sem_max1024_o256	content	titulo	None	palavras_aprox
c1024_o256	content	titulo	None	palavras_aprox

Observação técnica importante

O campo 'titulo' não representa a seção real do conteúdo; ele representa o título do documento, como 'Boletim 100 (IAC)'. As seções reais aparecem no início do campo content, por exemplo '5. MANEJO DA ADUBAÇÃO FOSFATADA'. Portanto, a métrica secao_preenchida_% ficou 100%, mas ela mede presença de título do documento, não preservação real de cabeçalho/seção.

2.2 Ajustes de código incorporados ao notebook

- Remoção de input(), getpass() e dependência de Colab Secrets na configuração do Qdrant.
- Criação de função robusta scroll_colecao() para paginar todos os pontos via /points/scroll.
- Validação de variáveis globais obrigatórias antes de iniciar a coleta.
- Auto-deteção de campo textual em payload direto ou aninhado.
- Fallback para seleção do maior campo string quando nenhum nome conhecido é encontrado.
- Detecção de campo de tokens quando existir token_count, n_tokens, num_tokens etc.
- Fallback para contagem aproximada por palavras quando não há campo de token no payload.
- Geração de tabela comparativa com n, min, p25, mediana, p75, max, média, desvio padrão, CV, percentual <= teto e > teto.
- Geração de histograma comparativo e exportação dos resultados em CSV/PNG.

Ajuste recomendado após a análise

O payload possui o campo 'chunk_size', mas ele não foi reconhecido como campo de tokens. Como a estratégia se chama max1024, é recomendável adicionar 'chunk_size' à lista de campos de tamanho/tokens do notebook e gerar uma segunda versão do histograma usando chunk_size_payload, além da versão por palavras aproximadas.

3. Resultado quantitativo do Critério 1

Coleção	n	Min	P25	Mediana	P75	Max	Média	DP	CV %	<= teto %	> teto
struct_se m_max1 024_o25 6	1283	3	110.0	139.0	160.0	218	130.5	39.7	30.4	100.0	0
c1024_o 256	991	73	159.0	167.0	176.0	205	167.5	12.1	7.2	100.0	0

Tabela 1 - Distribuição de tamanho dos chunks segundo a unidade usada pelo notebook: palavras aproximadas.

Interpretação: a estratégia struct_sem_max1024_o256 apresentou CV de 30,4%, enquanto o chunk fixo c1024_o256 apresentou CV de 7,2%. Isso demonstra que o struct_sem gera chunks com maior variabilidade de tamanho, coerente com a ideia de escalonamento dinâmico. No entanto, essa métrica mede variabilidade de tamanho, não melhora de acurácia ou recuperação em 30%.

3.1 Histograma comparativo

A figura abaixo mostra a distribuição dos tamanhos dos chunks para as duas coleções. A linha tracejada indica o teto de 1024 usado como referência no notebook.




Figura 1 - Histograma gerado pelo notebook para o Critério 1. Unidade: palavras aproximadas.

Leitura correta da figura

O histograma confirma que o struct_sem é mais disperso e o fixo é mais concentrado. Porém, como a unidade usada foi palavras aproximadas e não token_count real, a figura deve ser usada como evidência de comportamento relativo, não como prova absoluta do teto de tokens.

4. Resultado das avaliações de desempenho

Além da análise estrutural do tamanho dos chunks, foram consideradas duas avaliações independentes: uma avaliação ponta-a-ponta com geração de resposta e uma avaliação de recuperação. Ambas indicam que o ganho de 30% não foi atingido.

4.1 Avaliação ponta-a-ponta do Pedro

Estratégia	Corretas (10)	Incompletas (5)	Erradas (3)	Percentual
c1024_o256 (fixo)	15	2	16	63,03%
struct_sem_max1024_o256	14	3	16	61,52%

Interpretação: nessa avaliação, o método fixo ficou levemente acima. A diferença é pequena e está dentro de uma faixa compatível com empate técnico, mas não favorece o struct_sem.

4.2 Avaliação de recuperação do Henrique

Configuração	Score	Posição
struct (800 / 1024)	0,7305	1º / 2º
recursive (800)	0,7280	3º
recursive (1024)	0,7131	4º
flat (800)	0,7121	5º
flat (1024)	0,7062	6º

Interpretação: nessa avaliação, o struct aparece como melhor, mas com vantagem pequena: aproximadamente 3,4% contra flat 1024 e 2,6% contra flat 800. Isso não chega ao critério de 30%.

5. Análise do critério de 30%

Conclusão sobre o aceite

O critério de 30% não foi atingido. Não há 10 testes mostrando ganho igual ou superior a 30% do struct_sem sobre o fixo. As evidências disponíveis mostram diferenças pequenas, às vezes a favor do fixo e às vezes a favor do struct_sem, dependendo da camada avaliada.

A diferença entre as estratégias parece pequena porque as métricas medem etapas diferentes do pipeline:

- A avaliação de recuperação mede se o trecho correto aparece entre os chunks recuperados; nela, a segmentação estrutural pode ter leve vantagem.
- A avaliação ponta-a-ponta mede a resposta final gerada pelo LLM; nela, a etapa de geração pode diluir ou anular a vantagem da recuperação.
- As perguntas erradas por ambas as estratégias indicam que o gargalo principal pode estar na recuperação de tabelas, no reranking, no prompt ou no modelo gerador, e não apenas no chunking.

5.1 Por que o CV de 30,4% não resolve o critério

O CV de 30,4% comprova que o tamanho do chunk varia mais no struct_sem do que no fixo. Porém, o critério do card pede resultado melhor que o fixo em 30% ou mais. Portanto, não basta mostrar que a variação de tamanho é 30%; seria necessário mostrar ganho de desempenho, por exemplo em Recall@k, MRR, acurácia ou score de resposta, em 10 testes.

6. Problemas e ressalvas metodológicas identificados

Ponto	Impacto	Ação recomendada
Campo de tokens não detectado	O notebook usou palavras aproximadas, não token count real.	Adicionar 'chunk_size' aos campos de tamanho e gerar análise complementar.
Campo de seção detectado como título	O código mede título do documento, não seção real.	Extrair cabeçalhos do início do content ou salvar seção real no payload.
Amostra pequena de 33 perguntas	Poucas perguntas tornam diferenças de 1 ou 2 acertos muito instáveis.	Ampliar para 50-100 perguntas manuais ou automatizar recuperação para 300+.
Métricas distintas entre Pedro e Henrique	As avaliações não são 100% comparáveis.	Padronizar overlap, configuração, top-k e métrica.
Ganhos pequenos	Não sustentam adoção por 30% de melhora.	Justificar adoção por estrutura/interpretabilidade, não por ganho quantitativo alto.

7. Veredito final

Pergunta	Resposta final
A estratégia struct_sem_max1024_o256 funciona?	Sim. Ela gerou 1283 chunks, respeitou o teto na medição e apresentou variabilidade maior que o fixo.
O escalonamento dinâmico foi demonstrado?	Sim. O CV de tamanho foi 30,4% no struct_sem contra 7,2% no fixo.
O ganho de 30% foi atingido?	Não. Os ganhos observados foram pequenos e não chegam ao patamar exigido.
A tarefa pode ser marcada como 100% concluída?	Não pelo critério original. A conclusão correta é parcial.
Qual é a recomendação?	Registrar transparência no card, ajustar o critério ou executar nova avaliação focada em recuperação automática.

Formulação recomendada para o card: "A estratégia struct_sem_max1024_o256 foi validada quanto ao funcionamento do escalonamento dinâmico, apresentando maior variabilidade de tamanho e respeitando o teto configurado. Contudo, o critério de ganho de 30% sobre o chunk fixo não foi atingido nas avaliações disponíveis. A adoção progressiva pode ser considerada por critérios estruturais e de rastreabilidade, mas não por superioridade quantitativa de 30%."

Anexo A - Evidências do notebook corrigido

A.1 Saída de inspeção das coleções

```
struct_sem_max1024_o256
- Campo de texto: content
- Campo de seção detectado: titulo
- Campo de tokens: None
- Unidade usada para tamanho: palavras_aprox
- Total carregado: 1283 chunks

c1024_o256
- Campo de texto: content
- Campo de seção detectado: titulo
- Campo de tokens: None
- Unidade usada para tamanho: palavras_aprox
- Total carregado: 991 chunks
```

A.2 Exemplo de payload observado

```
{
  'content': '5. MANEJO DA ADUBAÇÃO FOSFATADA...',
  'chunk_index': 320,
  'chunk_size': 879,
  'pagina_pdf': 124,
  'estrategia': 'struct_sem',
  'tipo': 'texto',
  'titulo': 'Boletim 100 (IAC)',
  'ano': '2022',
  'arquivo': 'Boletim 100_15.07.2022_FINAL - Fernanda Bochi Dos Santos.pdf'
}
```

A.3 Trecho técnico recomendado para evolução do código

```
# Recomendação: incluir chunk_size como campo de tamanho do payload
CAMPOS_TAMANHO = [
    'token_count', 'n_tokens', 'num_tokens', 'total_tokens',
    'tokens', 'chunk_tokens', 'chunk_size'
]

# Se chunk_size existir no payload, gerar unidade separada:
# unidade_tamanho = 'chunk_size_payload'
# Caso contrário, manter fallback:
# unidade_tamanho = 'palavras_aprox'
```

A.4 Próxima medição recomendada

Para fechar uma nova rodada mais robusta, recomenda-se gerar duas análises separadas:

- **Análise estrutural:** tamanho por chunk_size_payload, presença de cabeçalho real no início do content e percentual de chunks acima do teto.
- **Análise de recuperação:** Recall@k, MRR e nDCG usando perguntas com trecho-resposta esperado.
- **Análise ponta-a-ponta:** manter a pontuação manual apenas para uma amostra menor, pois 300 perguntas multiplicadas por duas configurações gerariam 600 julgamentos.