

RELATÓRIO TÉCNICO — DESENVOLVIMENTO E VALIDAÇÃO DE PIPELINE (2026)

Conversão, Estruturação e Vetorização de Documentos Científicos

Período: 05 de fevereiro de 2026 a 25 de março de 2026

1. Introdução

Este relatório apresenta as atividades desenvolvidas no período entre fevereiro e março de 2026, relacionadas à construção, documentação e validação de um pipeline voltado à conversão de documentos científicos em formatos estruturados e vetorizados.

O foco principal do trabalho foi garantir que documentos em PDF pudessem ser processados de forma automatizada, transformados em representações adequadas para uso em sistemas baseados em recuperação semântica e armazenados em banco vetorial.

Além do desenvolvimento técnico, também foram realizados testes práticos em diferentes ambientes computacionais, integração com APIs externas e experimentos com estratégias de chunking e vetorização.

2. Objetivo

O objetivo deste trabalho foi:

- Documentar completamente o pipeline desenvolvido
- Validar sua execução em ambiente real (servidor)
- Resolver limitações técnicas de infraestrutura
- Integrar o pipeline com APIs do ecossistema
- Testar estratégias de chunking e vetorização
- Avaliar custos de ferramentas utilizadas no processo

3. Desenvolvimento do Trabalho

3.1 Documentação do Pipeline

A primeira etapa consistiu na organização e documentação completa do pipeline de processamento de PDFs científicos.

Essa documentação incluiu:

- Estrutura geral do projeto
- Funcionamento de cada etapa do pipeline
- Descrição das funções principais
- Fluxo completo de processamento (entrada → vetorização → armazenamento)

O objetivo foi deixar o projeto compreensível não apenas para quem desenvolveu, mas também para outros membros da equipe ou futuras manutenções.

3.2 Testes em Ambiente de Servidor

Após a documentação, foram realizados testes para execução do pipeline em servidor.

Durante essa etapa, o script principal de extração de PDFs não funcionou como esperado. Após análise, foi identificado que o problema não estava no código, mas sim no hardware do servidor.

A CPU utilizada não possuía suporte à instrução AVX (Advanced Vector Extensions), necessária para execução adequada do PyTorch. Isso causava falhas na inicialização de bibliotecas essenciais para geração de embeddings.

Diante disso, foi elaborado um relatório técnico explicando:

- Por que o PyTorch não rodava no servidor
- A relação entre AVX e operações vetoriais
- O impacto direto dessa limitação no pipeline

Essa análise foi importante para justificar tecnicamente a mudança de ambiente.

3.3 Migração para Google Colab

Com a limitação do servidor, o pipeline foi migrado para o Google Colab.

A escolha foi feita porque o ambiente oferece:

- Compatibilidade total com PyTorch
- Suporte a instruções modernas de CPU

- Facilidade para execução e testes rápidos

Com isso, foi possível continuar o desenvolvimento sem precisar adaptar o código para limitações do hardware.

3.4 Integração com APIs

Durante o desenvolvimento, o pipeline deixou de ser apenas um script isolado e passou a se integrar com outras partes do sistema.

Foram realizadas duas integrações principais:

Entrada de dados

- Conexão com a API responsável pelo fornecimento de documentos científicos
- Automatização da ingestão de PDFs

Saída de dados

- Integração com o banco vetorial Qdrant hospedado no servidor
- Envio direto dos embeddings gerados pelo pipeline

Essa etapa foi importante porque aproximou o projeto de um cenário real de uso, com fluxo contínuo de dados.

3.5 Avaliação de Ferramentas e Custos

Também foram realizados testes com ferramentas utilizadas no pipeline, com foco principal em custo monetário, e não apenas em capacidade técnica.

Foram analisadas alternativas como:

- Ferramentas de parsing e extração
- Serviços de processamento
- Soluções utilizadas no pipeline

O objetivo foi entender:

- Qual ferramenta gera maior custo por processamento
- Se o custo se justifica pelo resultado
- Quais opções são mais viáveis para uso contínuo

Essa análise foi importante pensando em escalabilidade do projeto.

3.6 Testes de Chunking

Uma parte importante do trabalho foi a experimentação com diferentes estratégias de chunking.

Foram testadas duas abordagens principais:

- Chunks de 1024 caracteres (sem sobreposição)
- Chunks de 512 caracteres com overlap de 128 caracteres

Esses testes foram feitos para entender como o tamanho dos chunks influencia:

- A qualidade dos embeddings
- A recuperação de informação
- A coerência dos trechos armazenados

Na prática, foi possível observar diferenças na forma como o conteúdo era fragmentado e posteriormente recuperado.

3.7 Vetorização e Armazenamento

Após os testes de chunking, foram realizados processos de vetorização de documentos científicos.

As etapas incluíram:

- Geração de embeddings a partir dos textos
- Associação de metadados (arquivo, posição, tamanho do chunk)
- Inserção no banco vetorial Qdrant

Foram populadas coleções com diferentes configurações de chunking, permitindo comparações futuras.

4. Resultados

Durante o período analisado, foi possível:

- Estruturar completamente o pipeline de processamento
- Identificar limitações reais de execução em servidor
- Adaptar o ambiente de execução para garantir funcionamento
- Integrar o pipeline com APIs externas
- Validar estratégias de chunking na prática
- Popular o banco vetorial com dados reais

Além disso, a análise de custos trouxe uma visão mais realista sobre a viabilidade de uso das ferramentas no longo prazo.

5. Conclusão

O trabalho desenvolvido entre fevereiro e março de 2026 foi essencial para transformar o pipeline em algo funcional e aplicável em um contexto real.

Mais do que apenas implementar código, foi necessário:

- Entender limitações de infraestrutura
- Adaptar o ambiente de execução
- Testar diferentes abordagens na prática
- Pensar em integração e escalabilidade

Os resultados obtidos mostram que o pipeline está em um estágio sólido de desenvolvimento, com base suficiente para evoluções futuras, principalmente nas áreas de otimização, automação e melhoria da qualidade da recuperação semântica.

6. Próximos Passos

As próximas etapas do trabalho serão direcionadas ao aprofundamento técnico do pipeline e à validação prática em cenários mais próximos do uso final.

6.1 Vetorização de Gráficos e Imagens

Uma das principais evoluções previstas é a expansão do pipeline para lidar com conteúdos não textuais, especialmente:

- Gráficos científicos
- Figuras técnicas
- Imagens presentes nos documentos

O objetivo é desenvolver ou integrar abordagens que permitam transformar esses elementos em representações vetoriais úteis para recuperação semântica.

Esse processo apresenta desafios adicionais, pois diferentemente do texto, gráficos e imagens carregam informação visual que precisa ser interpretada antes da vetorização.

Portanto, serão avaliadas estratégias como:

- Extração de texto embutido em imagens (OCR)

- Geração de descrições semânticas
- Uso de modelos multimodais

Essa etapa é fundamental para ampliar a cobertura do pipeline e evitar perda de informação relevante presente nos documentos.

6.2 Validação Iterativa de Estratégias de Chunking

Outra frente importante será a realização de testes iterativos para ajuste das estratégias de chunking.

A proposta é avaliar diferentes configurações de segmentação de texto (tamanho de chunks e overlap) com base no impacto real na qualidade das respostas geradas pelo sistema final.

Esse processo será conduzido da seguinte forma:

- Geração de embeddings com diferentes tamanhos de chunk
- Integração com o sistema de chatbot baseado em LLM
- Avaliação das respostas retornadas em consultas reais
- Coleta de feedback da equipe responsável pela camada de aplicação

Com base nesses testes, será possível identificar:

- Qual tamanho de chunk oferece melhor equilíbrio entre contexto e precisão
- Como o overlap influencia a continuidade semântica
- Quais configurações geram melhores resultados na prática

Esse tipo de validação é importante porque permite ajustar o pipeline não apenas com base em teoria, mas considerando o comportamento real do sistema em uso.

6.3 Expansão dos Testes em Ambiente Integrado

Também está prevista a ampliação dos testes em um ambiente mais integrado, conectando:

- Pipeline de ingestão
- Banco vetorial
- Sistema de recuperação (RAG)
- Interface de chatbot

Essa integração permitirá avaliar o desempenho do sistema como um todo, identificando possíveis gargalos e pontos de melhoria.

