

Relatório de Requisitos — Pipeline Completo

Stack analisada

Componente	Função
docling + pytesseract	PDF → Markdown (OCR + layout AI)
sentence-transformers (Qwen3-Embedding-0.6B)	Embeddings densos
transformers (OpenSearch Neural Sparse)	Embeddings esparsos
qdrant-client	Banco vetorial
ChartVLM	Interpretação de gráficos (multimodal)
LlamaIndex	Orquestração RAG

Por que o servidor atual falha

Requisito	Servidor Atual	Mínimo Necessário
AVX/AVX2	Ausente	Obrigatório para PyTorch
GPU NVIDIA	Ausente	Obrigatório para ChartVLM
CUDA	Ausente	Obrigatório
CPU moderna	Family 15 / KVM genérico	Mínimo Haswell (2013+)

Requisitos mínimos para rodar o pipeline

CPU

Arquitetura Intel Haswell (2013+) ou AMD equivalente.

Suporte obrigatório a AVX2.

Mínimo 8 cores (recomendado 16+).

RAM: mínimo 32 GB (recomendado 64 GB para processar PDFs grandes em paralelo).

GPU

Cenário	VRAM necessária	GPU indicada
Mínimo viável (quantização 4-bit)	8–10 GB	RTX 3080 / RTX 4070
Recomendado (FP16 estável)	16–24 GB	RTX 4090 / A10G / RTX 3090
Produção confortável	40–80 GB	A100 / H100

Para rodar Qwen3-Embedding, OpenSearch Sparse e ChartVLM simultaneamente, 24 GB de VRAM é um ponto de segurança prático.

Storage

Mínimo 100 GB SSD. PDFs e modelos baixados via HuggingFace podem ocupar entre 30 e 50 GB.

Software

Componente	Versão recomendada
Sistema operacional	Ubuntu 20.04+ (glibc ≥ 2.28)
Python	3.10+
CUDA	11.8 ou 12.x
Drivers NVIDIA	Atualizados

Opções de ambiente recomendadas

Opção	Onde	Custo aproximado	Viabilidade
Google Colab Pro+	Cloud	~\$50/mês	Bom para desenvolvimento e testes
RunPod / Vast.ai	Cloud	~\$0.50–1.50/hora	Alto custo-benefício
Lambda Labs	Cloud	~\$1.10/hora (A10G)	Ambiente estável
Servidor próprio	On-premise	Alto CAPEX	Viável para longo prazo

Conclusão

O servidor atual não possui condições de executar partes do pipeline que dependem de PyTorch devido à ausência de AVX2 e GPU. Para executar o stack completo com ChartVLM e LlamaIndex, o requisito mínimo prático é uma GPU NVIDIA com pelo menos 16 GB de VRAM e uma CPU com suporte a AVX2. Para maior estabilidade em produção, recomenda-se 24 GB de VRAM (por exemplo: RTX 4090, A10G ou RTX 3090). Para desenvolvimento e testes rápidos, serviços como Google Colab Pro ou RunPod são opções viáveis.