

RELATÓRIO TÉCNICO

Análise de Incompatibilidade de Hardware para Execução de Modelos Baseados em PyTorch e ChartVLM

Aluno: Nicolas Silva

Programa: Iniciação Científica

Projeto: Pipeline de Extração Estruturada de PDFs (OCR + Modelos de Layout + Modelos Multimodais)

Ambiente Avaliado: Servidor Linux Virtualizado (KVM)

Data: 02/03/2026

1. Objetivo

O presente relatório tem como objetivo demonstrar que a falha observada na execução do pipeline de Inteligência Artificial não decorre de erro no código-fonte desenvolvido, mas sim de limitações estruturais do ambiente computacional disponibilizado, especialmente relacionadas à ausência de suporte às instruções vetoriais AVX/AVX2, inexistência de GPU com suporte a CUDA e virtualização com CPU genérica sob KVM. Além disso, este relatório antecipa impactos técnicos relacionados à futura implementação da biblioteca ChartVLM.

2. Contextualização do Projeto

O projeto utiliza o framework PyTorch, backend matemático oneDNN/MKLDNN, modelos convolucionais (Conv2D) para análise de layout e processamento OCR estruturado. Está prevista a implementação futura da biblioteca ChartVLM, modelo multimodal voltado à interpretação de gráficos e elementos visuais complexos em documentos.

3. Diagnóstico do Ambiente Computacional

O servidor é uma máquina virtual sob hipervisor KVM, utilizando CPU virtual genérica (Common KVM processor, CPU family 15). A verificação técnica demonstra ausência de suporte às instruções AVX, AVX2 e FMA, limitando-se a SSE e SSE2. Não há GPU NVIDIA instalada, não há suporte a CUDA e o controlador gráfico identificado é virtual (Device 1234:1111).

4. Erro Observado no PyTorch

Durante a execução de operações convolucionais ocorre o erro 'RuntimeError: could not create a primitive'. O backend oneDNN tenta gerar kernels otimizados utilizando AVX/AVX2 e, na ausência dessas instruções, falha na criação de primitivas matemáticas internas. O erro ocorre em nível estrutural, não estando relacionado à lógica do código desenvolvido.

5. Impacto da Futura Implementação da ChartVLM

A biblioteca ChartVLM baseia-se em arquitetura Transformer e redes neurais profundas, exigindo operações vetorizadas intensivas, alto uso de matrizes e dependência direta de PyTorch. Sem suporte a AVX/AVX2 ou GPU com CUDA, o modelo pode não inicializar corretamente, apresentar falhas de kernel interno ou desempenho impraticável. Portanto, sua implementação no ambiente atual é tecnicamente inviável.

6. Impacto Geral para o Projeto

A ausência de AVX, AVX2 e GPU com CUDA implica instabilidade do PyTorch moderno, impossibilidade de execução de modelos multimodais, limitação severa de expansão do projeto, risco de incompatibilidade futura e redução significativa de desempenho, comprometendo a evolução científica da pesquisa.

7. Recomendações Técnicas

Recomenda-se: (1) Configuração da VM em modo CPU host-passthrough no KVM para exposição das instruções reais do processador; ou (2) Provisionamento de CPU com suporte a AVX/AVX2 (Intel Haswell ou superior, ou AMD equivalente); ou (3) Adoção de arquitetura alternativa com desenvolvimento em ambiente com GPU e uso do servidor apenas como backend leve.

8. Conclusão

Conclui-se que o problema identificado não decorre de falha no código desenvolvido, mas de limitações estruturais do ambiente computacional. A futura implementação da ChartVLM também não será viável nas condições atuais, reforçando a necessidade de adequação da infraestrutura para garantir continuidade, escalabilidade e evolução do projeto de pesquisa.